

# Compression

16 avril 2018

## Table des matières

<b>1</b>	<b>COMPRESSION DE DONNEES</b>	<b>2</b>
1.1	On data compressebility . . . . .	2

# 1 COMPRESSION DE DONNEES

site slides : [www.lrde.epita.fr/~gtochon/COD0/](http://www.lrde.epita.fr/~gtochon/COD0/)

Compression + decompression

Sans compression de donnees, un film 720p d'une heure ferait presque 400Gio.

La naissance naive de la compression de donnees est nee a peu pres en meme temps que le code morse. La naissance mathematique est avec Shannon.

Autre acteurs : - Abraham Lempel - David Huffman - Terry Welch

Le but de la compression est que lors de la decompression, ce soit le moins visible possible par l'utilisateur.

## 1.1 On data compressibility

On va chercher a eliminer les redondances, et les gaspillages. L'outil que l'on va utiliser est l'entropie.

Du point de vue de Shannon, plus un message va etre probable, moins il va contenir d'informations.

Prenons un alphabet de N symboles

$$\Sigma = \{s_1, s_2, \dots, s_N\}$$

de probabilté  $p(s_1) = \text{proba} (s_1 \text{ apparait})$  N valeurs de proba

$$P_1, \dots, P_N$$

avec  $\sum P_i = 1$

F un fichier construit sur cet alphabet  $\Sigma$  / distribution de proba  $(P_1, P_N)$   
→ qte d'information totale du symboles  $s_i = -\log_2(P_i)$

F contient  $N_F$  symboles →  $S_i$  est statiquement present  $N_F P_i$

$$Q_{Tot}(S_i) = -N_F P_i \log_2(P_i)$$

$$Q_{Tot}(F) = Q_{Tot}(S_1) + Q_{Tot}(S_2) + \dots + Q_{Tot}(S_N)$$

$$Q_{Tot}(S_1) = -N_F P_1 \log_2(P_1)$$

$$Q_{Tot}(S_2) = -N_F P_2 \log_2(P_2)$$

$$Q_{Tot}(S_N) = -N_F P_N \log_2(P_N)$$

$$Q_{Tot}(F) = \sum -N_F P_i \log_2(P_i) = -N_F \sum P_i \log_2(P_i)$$

Un gros fichier "probable" contient plus d'info qu un petit fichier "improbable"  $Q_{Tot} \rightarrow Sh$

$\rightarrow H \rightarrow \text{Sh/Symbole } H = -\sum P_i \log_2(P_i) \rightarrow$  ne depend pas du fichier considere, mais uniquement de la distribution de proba des symboles composant le fichier.

$X$  variable aleatoire de valeur  $\{x_1, x_2 \dots x_n \rightarrow P_i = P(X = x) \sum P_i = 1$   
 $E[X] = \sum_{i=1}^N x_i P(X = x_i) = \sum_{i=1}^N x_i P_i \quad E[\phi(X)] = \sum_{i=1}^N \phi(x_i) P_i \quad H = -\sum_{i=1}^N P_i \log_2 P_i = \sum_{i=1}^N (-\log_2(P_i)) P_i = \sum_{i=1}^N q_{S_i} P_i \quad H = E[q(s_i)] \quad \sum = 0, 1 \quad P(0) = P_0 = P \quad P(1) = P_1 = 1 - P \quad H = -p \log_2(p) - (1-p) \log_2(1-p) = H(p)$

— Missing things —

$\sum$  avec  $N$  symboles  $s_i, i = 1, \dots, N \quad (2^n)$

$$P(S_i) = \frac{1}{N_{\sum}} = \frac{1}{2^n}$$

$$H = -\sum_{i=1}^{N_{\sum}} \log_2(P_i) = -\sum_{i=1}^{2^n} = -\sum_{i=1}^{2^n} \frac{1}{2^n} \log_2\left(\frac{1}{2^n}\right) = \frac{1}{2^n} * (-n) * \sum_{i=1}^{2^n} * \sum_{i=1}^{2^n} 1 = n 2^n 2^{-n} = n$$

(Sh/Symbole)